

UNIVERSIDADE DE SÃO PAULO - INSTITUTO DE FÍSICA

---

*Tópicos em Mecânica Estatística de  
Sistemas Complexos*

---

RAFAEL S. CALSAVERINI

SÃO PAULO  
22 DE MAIO DE 2012



UNIVERSIDADE DE SÃO PAULO - INSTITUTO DE FÍSICA

---

# *Tópicos em Mecânica Estatística de Sistemas Complexos*

---

RAFAEL S. CALSAVERINI

Tese apresentada ao Instituto de Física  
da Universidade de São Paulo para  
obtenção do título de Doutor em Ciên-  
cias.

*Orientador:*

Prof. Dr. Nestor Felipe Caticha Alfonso

*Co-Orientador:*

Prof. Dr. Renato Vicente

SÃO PAULO  
22 DE MAIO DE 2012



# Sumário

<i>Resumo</i>	7
---------------	---

<i>Abstract</i>	9
-----------------	---

<i>Introdução</i>	11
-------------------	----

Visão geral . . . . .	11
Inferência . . . . .	11
Probabilidades e Inferência . . . . .	11
Informação e Máxima Entropia . . . . .	11
Inferência e Mecânica Estatística . . . . .	11
Uma visão informacional da Mecânica Estatística . . . . .	11
Distribuições de Gibbs . . . . .	11
Métodos de campo médio . . . . .	11
Tópicos tratados na Tese . . . . .	11
Dependência estatística . . . . .	11
Emergência de autoridade . . . . .	11

<i>Informação mútua, teoria de cópulas e dependência estatística</i>	13
--	----

Dependência Estatística e medidas de dependência . . . . .	13
O que se deseja de uma medida de dependência? . . . . .	15
Informação Mútua . . . . .	16
Cópulas . . . . .	16
Exemplos . . . . .	17
Dependência extrema - limites de Frechet-Hoeffding . . . . .	19
Medidas de dependência revisitadas . . . . .	19
Entropia de Cópula . . . . .	21
“Excesso” de informação mútua . . . . .	22

Correlação Linear <i>vs.</i> parâmetro . . . . .	22
Informação mútua para cópulas elípticas . . . . .	23
Excesso de Informação Mútua . . . . .	26
Ajuste empírico de cópulas via informação mútua . . . .	27
Cópula $t$ . . . . .	31
Conclusões . . . . .	32

## *Um Modelo para emergência de autoridade em sociedades humanas.* 35

Introdução . . . . .	35
Evidências empíricas . . . . .	35
“U-shaped evolution” e dinâmica da organização social em primatas pré-humanos . . . . .	35
. . . . .	36
Evolução do cérebro primata e a Teoria Maquiavélica . .	36
Dados etnoráficos (?) . . . . .	37
Um modelo mecanico-estatístico baseado em agentes . . . .	37
Modelo de Agentes . . . . .	37
Representação da Estrutura Social . . . . .	37
Custo social e custo cognitivo . . . . .	37
Dinâmica para agentes isolados - máxima entropia . . .	39
Interpretação do parâmetro $\beta$ . . . . .	40
Resultados numéricos para agentes isolados . . . . .	40
Dinâmica para muitos agentes . . . . .	43
Resultados numéricos para muitos agentes . . . . .	45
Sumarização e interpretação dos Resultados . . . . .	45
Conclusão . . . . .	45

## *Conclusão e Observações Finais* 47

... . . . .	47
... . . . .	47
... . . . .	47

## *Referências Bibliográficas* 49

## Lista de Figuras

1	Representação pictórica da projeção de uma distribuição.	16
2	A correlação linear é subestimada no caso de marginais não-Gaussianas. . . . .	22
3	Estimativas para a informação mútua <i>vs.</i> tau de Kendall para séries financeiras. . . . .	28
4	Seleção de pares de ações. . . . .	29
5	Excesso de informação mútua na cópula $t$ . . . . .	33
6	Ilustração da história da organização social dos humanos e primatas pré-humanos. . . . .	36
7	Gráfico em escala di-logaritimica do tamanho médio do grupo em função da razão média entre o volume do neo-córtex e o volume total do cérebro para diversas espécies de primatas. Dados disponíveis em [8]. . . . .	37
8	Grafo totalmente conectado . . . . .	39
9	Grafo estrela . . . . .	39
10	Corte do diagrama de fases apresentando a média térmica obtida via Monte Carlo. . . . .	40
11	Diagrama de fases apresentando a razão $\frac{d_{avg}}{d_{max}}$ em função de $\alpha$ e temperatura, para um número fixo de agentes. . .	41
12	Valor crítico do parâmetro $a$ em função da temperatura para diferentes tamanhos do sistema. . . . .	42
13	Parâmetros de ordem associados à correlação entre grafos de diferentes agentes . . . . .	44

,





## *Resumo*

Das ist ein text von Goethe. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.



## *Abstract*

Das ist ein lied von Klaus Hoffman.Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consetetuer.



# *Introdução*

*Visão geral*

*Inferência*

*Probabilidades e Inferência*

*Informação e Máxima Entropia*

*Inferência e Mecânica Estatística*

*Uma visão informacional da Mecânica Estatística*

*Distribuições de Gibbs*

*Métodos de campo médio*

*Tópicos tratados na Tese*

*Dependência estatística*

*Emergência de autoridade*



# *Informação mútua, teoria de cópulas e dependência estatística*

## *Dependência Estatística e medidas de dependência*

O CONCEITO DE DEPENDÊNCIA ESTATÍSTICA é central à teoria de probabilidades. Fazer hipóteses a respeito da dependência estatística entre as variáveis de interesse em um modelo é comum em diversas áreas – da física à análise financeira. Não é óbvio, entretanto, como expressar esse conceito de maneira precisa. A formalização precisa desse conceito é um dos objetivos desse capítulo. De maneira informal e grosseira, dependência estatística diz respeito a quanta *informação* se obtém a respeito de uma variável quando o valor de outra variável é conhecido. Os dois casos extremos podem ser mais facilmente entendidos em primeira análise: o caso de completa independência e o caso de completa dependência. Duas variáveis são ditas independentes se sua distribuição conjunta pode ser fatorada em um produto<sup>1</sup>:

$$p_{X,Y}(x,y) = p_X(x)p_Y(y). \quad (1)$$

De maneira similar, pode-se dizer que duas variáveis são independentes quando a distribuição condicional  $p(x|y)$  é idêntica à distribuição marginal de  $X$  -  $p_X(x)$ . Nessa situação, o conhecimento do valor da variável  $Y$  não fornece qualquer informação a respeito da variável  $X$ . Duas variáveis são ditas completamente dependentes quando uma pode ser escrita como função monotônica da outra:

$$x = F(y). \quad (2)$$

Nesse caso, o conhecimento de uma das variáveis determina completamente o valor de outra. Ou seja  $p(x|y) = \delta(x - F(y))$ , com  $F(\cdot)$  uma função monotônica. Pode-se, dessa maneira, tentar introduzir alguma forma concreta de medir a dependência estatística em um parâmetro que possa ser estimado e usado para caracterizar a dependência entre variáveis de forma mais concreta.

<sup>1</sup> Manteremos o foco de nossa atenção em distribuições bivariadas, uma vez que a generalização é imediata.

<sup>2</sup> A rigor, o módulo da correlação linear. A correlação linear mede, além de dependência, concordância, ou seja, quanto duas variáveis reais apresentam variação coordenada de seus sinais. Essa informação extra não é captada apenas pelo conceito de dependência.

UM PARÂMETRO COMUMENTE USADO para esse fim é a chamada correlação linear<sup>2</sup>

$$\hat{\rho}_{XY} = \frac{E[XY] - E[X]E[Y]}{\sigma_X\sigma_Y} = \frac{\text{Cov}(X, Y)}{\sigma_X\sigma_Y}. \quad (3)$$

A correlação linear  $\hat{\rho}$  é um número real no intervalo  $[-1, 1]$ , simétrica com relação à transposição de  $X$  e  $Y$  que sempre se anula quando duas variáveis são independentes. É certamente a medida mais popular de dependência utilizada em todo tipo de análise estatística. Entretanto, seria mais preciso dizer que a correlação linear, como a nomenclatura aqui empregada sugere, é apenas uma medida de dependência linear. Há diversas falhas dessa medida em capturar a completa dependência entre duas variáveis. Em particular é fácil notar que é possível obter duas variáveis com correlação linear nula em que, entretanto, haja forte dependência entre ambas. Um exemplo simples é o par de variáveis definido por:

$$Y = f(X) + \epsilon \quad (4)$$

em que  $X$  e  $\epsilon$  sejam independentes e tenham distribuições simétricas em torno da origem e  $f(\cdot)$  seja qualquer função par. Nesse caso temos:

$$\text{Cov}(X, Y) = E[Xf(X)] + E[X]E[\epsilon] - E[X]E[f(X)]$$

Note que se a distribuição de  $X$  é uma função par, então o valor esperado de qualquer função ímpar de  $X$  é nulo, o que anula a expressão acima. Dessa forma temos  $\hat{\rho}_{XY} = 0$ . Entretanto, caso a distribuição de  $\epsilon$  seja bastante concentrada em torno da origem, o conhecimento de  $X$  pode fornecer informação quase completa a respeito de  $Y$ . Essa informação não é capturada pela correlação linear. O epíteto “linear”, usado nesse trabalho para descrever a correlação, pode ser melhor compreendido se notarmos uma propriedade interessante da correlação: ela é invariante por mudanças de escala lineares nas variáveis  $X$  e  $Y$ . Uma reparametrização do tipo:

$$X' = \alpha_X X + \beta_X$$

$$Y' = \alpha_Y Y + \beta_Y$$

não muda o valor da correlação linear:  $\hat{\rho}_{X'Y'} = \hat{\rho}_{XY}$ . Entretanto uma mudança mais geral de escala não preserva essa propriedade. Uma nova variável:

$$Y' = g(Y)$$

com  $g(\cdot)$  monotônica, a princípio contém exatamente a mesma informação a respeito de  $X$  que a antiga variável  $Y$ . Entretanto não se garante que a correlação se mantenha invariante. Seria esperado, além disso, que a afirmação de que a correlação entre duas variáveis é máxima em módulo fosse uma indicação de que a dependência entre as duas variáveis é máxima. Entretanto, isso não é garantido.



### *O que se deseja de uma medida de dependência?*

A DIGRESSÃO ACIMA acerca da natureza da correlação linear imediatamente suscita a pergunta: que parâmetros são boas medidas de dependência e quais são suas características? Pode-se enumerar uma série de desejos a respeito dessas medidas que se baseiem na noção intuitiva de dependência como o conteúdo de informação de uma variável a respeito de outra. Explicitamente, esperamos que:

1. uma boa medida de dependência seja um funcional  $R : P_2 \rightarrow \mathbb{R}$  da distribuição conjunta de probabilidades, bem definido para qualquer par de variáveis aleatórias  $X$  e  $Y$ ;
2. o funcional seja invariante sob permutação das variáveis  $X$  e  $Y$ :  $R(X, Y) = R(Y, X)$ ;
3. o funcional seja nulo *se, e somente se* as variáveis forem estritamente independentes;
4. o funcional atinja um valor máximo *se, e somente se* as variáveis apresentem dependência máxima, ou seja, sejam funções monotônicas uma da outra;
5. o funcional seja invariante por escolhas de novas variáveis  $(X, Y) \rightarrow (U = u(X), V = v(Y))$  desde que nenhuma informação seja perdida, ou seja, desde que  $u(\cdot)$  e  $v(\cdot)$  sejam funções bijetoras;
6. o funcional seja uma função monotônica e crescente do módulo da correlação linear para o caso de distribuições conjuntas gaussianas.

Essa série de requisitos, essencialmente<sup>3</sup> enumerados pela primeira vez<sup>4</sup> por Renyi [18], não são suficientes para escolher um parâmetro único e são satisfeitos por uma grande variedade de diferentes parâmetros usados em estatística. Como exemplo podemos citar o  $\tau$  de Kendall. Dados dois pares,  $(X_1, Y_1)$  e  $(X_2, Y_2)$ , de pontos sorteados independentemente da distribuição  $p_{XY}(x, y)$ , o  $\tau$  de Kendall é dado por:

$$\begin{aligned} \tau_{XY} &= \mathbb{Pr}[(X_1 - X_2)(Y_1 - Y_2) > 0] - \mathbb{Pr}[(X_1 - X_2)(Y_1 - Y_2) < 0] \\ &= 4 \int F(x, y) dF(x, y) - 1, \end{aligned}$$

onde  $F(x, y)$  é a distribuição cumulativa de  $X$  e  $Y$ . Outra medida que satisfaz esses requisitos é a correlação de postos de Spearman dada por:

$$\rho_{XY}^S = 12 \int (F(x, y) - F_X(x)F_Y(y)) dF_X(x)dF_Y(y), \quad (5)$$

onde  $F_X(x)$  e  $F_Y(y)$  são as distribuições cumulativas marginais de  $X$  e  $Y$  respectivamente.

<sup>3</sup> Renyi exigia ainda que a medida tomasse valores no conjunto  $[0, 1]$ , o que dispensamos, uma vez que é sempre possível transpor uma medida no intervalo  $[0, \infty]$  para esse conjunto através de uma função monotônica. Além disso há requisitos de continuidade e convergência para sequências convergentes de distribuições.

<sup>4</sup> A. Renyi. On measures of dependence. *Acta. Math. Acad. Sci. Hungar.*, 10:441–451, 1959; and B. Schweizer and E. F. Wolff. On nonparametric measures of dependence for random variables. *The Annals of Statistics*, 9(4):879 – 885, 1981




Figura 1 – Representação pictórica da projeção de uma distribuição em uma certa família de distribuições convenientes. O espaço representado na figura corresponde de forma pictórica ao espaço formado por todas as distribuições de probabilidade. A superfície corresponde a um sub-espaço, nesse caso, o sub-espaço de distribuições fatoráveis, correspondentes a variáveis independentes. A projeção de uma distribuição qualquer  $q(x, y)$  sobre esse sub-espaço através da minimização da divergência de Kullback-Leibler resulta na distribuição dada pelo produto das distribuições marginais  $q(x)q(y)$ .

<sup>5</sup> Alguns autores reservam o nome Informação Mútua para o caso de duas variáveis

## Informação Mútua

DO PONTO DE VISTA DE TEORIA DE INFORMAÇÃO a dependência mútua de um conjunto de variáveis pode ser quantificada através da mínima “distância na variedade estatística” (divergência de Kullback-Leibler) entre a distribuição conjunta dessas variáveis e a “sub-variedade” de distribuições independentes (veja figura 1) Isso pode ser escrito da forma:

$$I(X_1, \dots, X_n) = \min_{\{\phi_i(x_i)\}} \int p(x_1, \dots, x_n) \log \frac{p(x_1, \dots, x_n)}{\prod_{i=1}^n \phi_i(x_i)} \prod_{i=1}^n dx_i \quad (6)$$

Fazendo a derivada funcional da expressão a ser minimizada com relação às distribuições indeterminadas  $\phi_k(x)$  obtemos a condição de extremo, com o vínculo de que as distribuições  $\phi_j(x)$  sejam normalizadas:

$$\phi_k(x_k) = \int p(x_1, x_2, \dots, x_n) \prod_{i \neq k} dx_i = p_{X_k}(x_k) \quad (7)$$

Ou seja: a distribuição  $\phi_j(x_j)$  devem ser a distribuição marginal da variável  $X_j$ , e podemos reescrever:

$$I(X_1, \dots, X_n) = \int p(x_1, \dots, x_n) \log \frac{p(x_1, \dots, x_n)}{\prod_{i=1}^n p_{X_i}(x_i)} \prod_{i=1}^n dx_i \quad (8)$$

Esse funcional que mede a dependência mútua entre grupos de variáveis é denominado Informação Mútua ou Correlação Total<sup>5</sup>. Interpretações para a o funcional podem ser obtidas notando que:

$$I(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i) - H(X_1, \dots, X_n) \quad (9)$$

$$= H(X_j) - H(X_j | X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_n) \quad (10)$$

Dessa forma, pode-se interpretar  $I(X_1, \dots, X_n)$  como a redução na incerteza a respeito da variável  $X_j$  proporcionada pelo conhecimento das variáveis  $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_n$ . A informação mútua para duas variáveis, dada por:

$$I(X, Y) = \int dx dy p(x, y) \log \frac{p(x, y)}{p_X(x) p_Y(y)}, \quad (11)$$

satisfaz todos os critérios discutidos na seção anterior para ser uma boa medida de dependência.

## Cópuas

A ELUCIDAÇÃO DO CONCEITO DE DEPENDÊNCIA eventualmente se choca com a noção de cópula<sup>6</sup>. Um teorema devido a Sklar<sup>7</sup> permite

<sup>6</sup> Roger B. Nelsen. *An Introduction to Copulas*. Springer Series in Statistics. Springer, New York, 2nd edition, 2006. ISBN 0387986235

<sup>7</sup> A. Sklar. Fonctions de répartition à n dimensions et leurs marges. *Publ. Inst. Statist. Univ. Paris*, 8:229–231, 1959

separar a distribuição cumulativa conjunta -  $F_{X,Y}(x,y)$  - de duas variáveis em duas partes: (a) as distribuições cumulativas marginais de cada variável -  $F_X(x)$  e  $F_Y(y)$ , que trazem informação idiossincrática a respeito de cada uma das variáveis (b) e uma função cópula  $C(u,v)$ , que traz informação sobre a dependência entre as variáveis. De maneira geral o teorema de Sklar pode ser enunciado da seguinte forma:

**Teorema 1** (Teorema de Sklar). *Para toda distribuição cumulativa conjunta contínua de duas variáveis  $F_{X,Y}(x,y)$ , com distribuições cumulativas  $F_X(x)$  e  $F_Y(y)$ , existe uma função cópula única  $C(u,v)$  tal que:*

$$F_{X,Y}(x,y) = C(F_X(x), F_Y(y)). \quad (12)$$

*Similarmente, dadas quaisquer duas distribuições cumulativas univariadas  $F_X(x)$  e  $F_Y(y)$  e uma função cópula  $C(u,v)$ , é possível construir uma distribuição conjunta dada por  $F_{X,Y}(x,y) = C(F_X(x), F_Y(y))$ .*

A PRÓPRIA FUNÇÃO CÓPULA é uma legítima distribuição cumulativa conjunta, associada às variáveis  $U = F_X(X)$  e  $V = F_Y(Y)$ :

$$F_{U,V}(u,v) = C(u,v)$$

Dessa forma, podemos também definir a densidade de cópula, a densidade de probabilidade das variáveis  $U$  e  $V$ :

$$p_{U,V}(u,v) = c(u,v) = \frac{\partial^2 C}{\partial u \partial v}$$

Essa definição implica que a densidade de probabilidade conjunta das variáveis  $X$  e  $Y$  é dada por:

$$p_{X,Y}(x,y) = c(F_X(x), F_Y(y))p_X(x)p_Y(y) \quad (13)$$

**dá para explicar isso melhor** O teorema de Sklar permite dividir a informação contida na distribuição conjunta em duas partes: a parte que diz respeito às propriedades de cada uma das variáveis, dada pelas distribuições marginais, e a parte que diz respeito à dependência estatística entre as duas variáveis.

### Exemplos

COMO EXEMPLOS DE FUNÇÕES CÓPULA temos as cópulas associadas às distribuições multivariadas mais comumente utilizadas. Qualquer família de distribuições multivariadas com um conjunto de parâmetros  $\theta$  dada por  $p(x,y|\theta)$  define uma função cópula dada por:

$$C(u,v|\theta) = \int_{-\infty}^{F_X^{-1}(u)} \int_{-\infty}^{F_X^{-1}(v)} dx dy p(x,y|\theta) \quad (14)$$

A cópula mais comumente empregada em todo tipo de análise estatística é a cópula normal ou gaussiana que, argumentaremos mais adiante, postula a mínima dependência linear entre duas variáveis:

$$N_\rho(u, v) = \frac{1}{2\pi\sqrt{1-\rho^2}} \int_{-\infty}^{\Phi^{-1}(u)} \int_{-\infty}^{\Phi^{-1}(v)} du dv e^{-\frac{u^2+v^2-2u\rho v}{2(1-\rho^2)}} \quad (15)$$

onde  $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp -u^2/2 du$  é a distribuição cumulativa normal padronizada. A família de cópulas normais depende apenas de um parâmetro  $\rho \in [-1, 1]$  que, *no caso em que sejam inseridas marginais gaussianas para formar uma distribuição conjunta*, é igual à correlação entre as variáveis assim distribuídas. É importante notar que, para quaisquer outras marginais, a correlação poderá uma função do parâmetro  $\rho$  e de quaisquer outros parâmetros dessas distribuições marginais. Essa família contém a cópula de variáveis independentes  $C(u, v) = uv$  quando  $\rho = 0$ .

UMA CÓPULA LIGEIRAMENTE MAIS COMPLICADA QUE A NORMAL é a cópula associada à distribuição t de Student que, além da dependência linear descrita pelo parâmetro  $\rho$ , apresenta também dependência nas caudas da distribuição. A distribuição t de Student bivariada padrão<sup>8</sup> é dada por:

$$p_T(x, y | \rho, \nu) = \frac{\Gamma(1 + \frac{\nu}{2})}{\Gamma(\frac{\nu}{2})\pi\nu\sqrt{1-\rho^2}} \left[ 1 + \frac{q_\rho(x, y)}{\nu} \right]^{-(1+\frac{\nu}{2})}, \quad (16)$$

onde  $q_\rho(x, y) = \frac{1}{1-\rho^2} [x^2 + y^2 - 2\rho xy]$ . As marginais dessa distribuição são distribuições t univariadas:

$$p(x_i | \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left( 1 + \frac{x_i^2}{\nu} \right)^{-(\frac{\nu+1}{2})} \quad (17)$$

No limite  $\nu \rightarrow \infty$  essa distribuição se reduz à distribuição normal bivariada padronizada, com parâmetro de correlação linear  $\rho$ , médias nulas e variâncias unitárias. Para  $\nu$  finito as marginais adquirem caudas pesadas e a dependência entre as variáveis ganham uma componente além da correlação linear - adicionando peso nas caudas da cópula. A cópula t pode ser obtida introduzindo essa distribuição na eq. (14):

$$C_T(u, v | \nu, \rho) = \frac{\Gamma(1 + \frac{\nu}{2})}{\Gamma(\frac{\nu}{2})\pi\nu\sqrt{1-\rho^2}} \int_{-\infty}^{t_v^{-1}(u)} \int_{-\infty}^{t_v^{-1}(v)} dx dy \left[ 1 + \frac{q_\rho(x, y)}{\nu} \right]^{-\frac{\nu+2}{2}} \quad (18)$$

onde  $t_\nu(x)$  é a distribuição cumulativa associada à distribuição univariada em (17).

<sup>8</sup> Médias não-nulas e variância diferente da unitária podem ser trivialmente acrescentadas através de translações e mudanças de escala. Uma vez que essas transformações só afetam as marginais e mantém a cópula invariante - são transformações inversíveis, coordenada a coordenada - não afetam a dependência

UMA TERCEIRA FAMÍLIA DE CÓPULAS que convém citar são as cópulas arquimedianas, que podem ser escritas como:

$$C(u, v | \Psi(\cdot)) = \Psi^{-1}(\Psi(u) + \Psi(v)) \quad (19)$$

parametrizadas por uma função  $\phi$ . Essas funções cópula existem desde que:  $\Psi(1) = 0$ ,  $\lim_{x \rightarrow 0} \Psi(x) = \infty$ ,  $\Psi'(x) < 0$  e  $\Psi''(x) > 0$ . Essa família contém a cópula de variáveis independentes quando  $\Psi(x) = -\log(x)$ .

### *Dependência extrema - limites de Frechet-Hoeffding*

A DEFINIÇÃO DE CÓPULA permite tornar mais preciso o conceito de dependência extrema. As equações (1) e (13) em conjunto nos permitem concluir que, para duas variáveis independentes:

$$c(u, v) = 1, \quad (20)$$

$$C(u, v) = uv, \quad (21)$$

Para o caso de dependência completa é possível mostrar que<sup>9</sup> toda cópula está limitada por duas funções que representam dependência máxima, denominadas limites de Frechet-Hoeffding. Essas funções são:

$$W(u, v) = \max(0, u + v - 1) \quad (22)$$

$$M(u, v) = \min(u, v) \quad (23)$$

Essas duas funções são elas próprias cópulas e limitam por cima e por baixo todas as outras cópulas possíveis:

$$W(u, v) \leq C(u, v) \leq M(u, v) \quad (24)$$

para qualquer possível cópula  $C(u, v)$ . As densidades de cópula associadas a essas duas funções evidenciam que casos descrevem:

$$w(u, v) = \delta(u + v) \quad (25)$$

$$m(u, v) = \delta(u - v). \quad (26)$$

Inserindo marginais  $F(x)$  e  $G(y)$  quaisquer, nota-se o tipo de distribuições conjuntas que essas cópulas geram: ambas descrevem duas variáveis com dependência monotônica - crescente no caso de  $M$  e decrescente no caso de  $W$ .

### *Medidas de dependência revisitadas*

Os "AXIOMAS" DE RENYI a respeito de medidas de dependência podem ser revisitados e tornados mais precisos com o conceito de cópula

<sup>9</sup> Roger B. Nelsen. *An Introduction to Copulas*. Springer Series in Statistics. Springer, New York, 2nd edition, 2006. ISBN 0387986235

e cópulas extremas em mãos. Os itens 1, 2 e 5 ficam imediatamente satisfeitos se a medida de dependência em questão for funcional apenas da cópula e não das distribuições marginais. Além disso, os itens 3 e 4 podem ser reescritos em termos das cópulas extremas e da cópula independente. Podemos reescrever então esses requisitos da seguinte forma:

- Uma boa medida de dependência entre duas variáveis  $X$  e  $Y$  é um funcional  $\mathcal{F} : \mathcal{C}_2 \rightarrow \mathcal{R}$  que leva funções cópula  $C_{XY}(\cdot, \cdot)$  em números reais e independe das distribuições marginais;
- atinge um valor mínimo, que será arbitrariamente escolhido como zero, se, e somente se,  $C_{XY}(u, v) = uv$ ;
- atinge um valor máximo quando  $C_{XY}(u, v) = W(u, v)$  ou  $C_{XY}(u, v) = M(u, v)$ .
- para  $C_{XY}(u, v) = N_\rho(u, v)$ , o funcional é um função monotônica crescente do parâmetro  $\rho$ .

A correlação linear falha em dois itens: é possível representar a correlação linear como função da cópula, mas não é possível eliminar sua dependência com as marginais:

$$\hat{\rho}_{X,Y} = \frac{1}{\sigma_X \sigma_Y} \int \int C(u, v) dF_X^{-1}(u) dF_Y^{-1}(v).$$

Essa expressão depende das marginais explicitamente nas medidas de integração e implicitamente nas variâncias  $\sigma_i$ . Além disso, a correlação não atinge seus valor extremo sempre que a cópula escolhida como uma das cópulas de Frechet-Hoeffding - o valor assumido nesse caso depende das marginais específicas. Outras medidas apresentadas acima, o tau de Kendall ( $\tau$ ) e a correlação de postos de Spearman ( $\rho^S$ ) podem ser facilmente escritas de forma a satisfazer todas os critérios acima:

$$\tau = 4 \int_0^1 \int_0^1 C(u, v) dC(u, v) - 1 \quad (27)$$

$$\rho^S = 12 \int_0^1 \int_0^1 [C(u, v) - uv] dudv \quad (28)$$

O último requisito pode ser verificado notando-se que, para o caso de cópulas normais, essas expressões se reduzem a<sup>10</sup>:

$$\tau = \frac{2}{\pi} \arcsin(\rho), \quad (29)$$

$$\rho^S = \frac{6}{\pi} \arcsin\left(\frac{\rho}{2}\right). \quad (30)$$

Além disso, a Informação Mútua, como mostraremos na próxima seção, também satisfaz os requisitos acima.

<sup>10</sup> A expressão para o tau de Kendall vale para toda distribuição elíptica, incluindo a distribuição t de Student

## Entropia de Cópula

PARA ESCREVER a informação mútua como um funcional da cópula basta recorrer à definição da densidade de cópula e a expressão da distribuição conjunta em termos desta, na eq. (13) que reproduzimos abaixo:

$$p_{XY}(x, y) = c(F_X(x), F_Y(y)) p_X(x) p_Y(y).$$

Usando essa expressão na definição de informação mútua eq. (11):

$$I(X, Y) = \int dx dy p(x, y) \log \frac{p(x, y)}{p_X(x) p_Y(y)},$$

temos:

$$\begin{aligned} I(X, Y) &= \int p_X(x) dx p_Y(y) dy c(F_X(x), F_Y(y)) \log [c(F_X(x), F_Y(y))] \\ &= \int du dv c(u, v) \log c(u, v) \end{aligned}$$

e portanto:

$$I(X, Y) = \int \int du dv c(u, v) \log c(u, v) = -S[c] \geq 0 \quad (31)$$

onde  $S[c]$  é a entropia associada à distribuição conjunta  $c(u, v)$ , daqui por diante denominada *entropia de cópula*<sup>11</sup>. Esse resultado oferece ainda mais uma interpretação aos múltiplos significados da informação mútua - que ressoa diretamente com a definição de dependência apresentada no início deste capítulo - é o conteúdo de informação associado à dependência entre duas variáveis. A combinação desse resultado com a eq. (9) permite escrever<sup>12</sup>:

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i) + H_{\text{cop}} \quad (32)$$

decompondo então a entropia, o conteúdo informacional da distribuição conjunta, em parcelas devidas às características de cada uma das variáveis e uma parcela correspondente ao acoplamento entre essas variáveis. Eq. (31) também oferece um conveniente princípio para encontrar cópulas informacionalmente neutras segundo o princípio de máxima entropia<sup>13</sup>: a cópula menos informativa é a que postula a menor informação mútua possível entre as variáveis.

O ÚLTIMO PASSO para mostrar que a informação mútua satisfaz todos os critérios para ser uma boa medida de dependência é notar que, no caso de cópulas gaussianas:

$$I(X_1, X_2) = -\frac{1}{2} \log(1 - \rho^2) \quad (33)$$

<sup>11</sup> Jian Ma and Zengqi Sun. Mutual information is copula entropy. *Tsinghua Science and Technology*, 16(1):51 – 54, 2011. ISSN 1007-0214. DOI: 10.1016/S1007-0214(11)70008-6. arXiv:0808.0845; and Rick L. Jenison and Richard A. Reale. The shape of neural dependence. *Neural Computation*, 16:665 – 672, 2004

<sup>12</sup> A expressão acima pode ser imediatamente generalizada para um número arbitrário de variáveis

<sup>13</sup> E. T. Jaynes. *Probability Theory: The Logic of Science*. Cambridge University Press, Cambridge, 2003

## “Excesso” de informação mútua

### Correlação Linear vs. parâmetro

A DISTRIBUIÇÃO DE MÁXIMA ENTROPIA que satisfaz vínculos de que correlação, médias, e variâncias de um par de variáveis  $X$  e  $Y$  assumam certos valores é a distribuição normal. Usando a decomposição da eq. (32), temos, uma vez que as entropias das marginais dependem apenas das variâncias e a informação mútua apenas da correlação<sup>14</sup>:

$$H(X_1, X_2) = h(\sigma_1) + h(\sigma_2) + \frac{1}{2} \log(1 - \hat{\rho}^2)$$

onde  $h(\sigma)$  é a entropia de uma distribuição normal univariada com variância  $\sigma^2$ . Se essa é a maior possível entropia dada a correlação e variâncias, e uma vez que a informação mútua independe das variâncias<sup>15</sup>, então o valor:

$$I_0(\hat{\rho}) = -\frac{1}{2} \log(1 - \hat{\rho}^2) \quad (34)$$

é um limite inferior para a informação mútua de qualquer par de variáveis que tenham correlação  $\hat{\rho}$ :

$$I_{XY} \geq I_0(\hat{\rho}_{XY}). \quad (35)$$

Dessa forma, representando formalmente em um plano  $I$  vs.  $\hat{\rho}$  as possíveis distribuições conjuntas com cópula gaussiana<sup>16</sup>, temos a figura 2.

NESSA FIGURA temos duas distribuições destacadas. Uma delas possui marginais gaussianas, sendo portanto uma distribuição normal bivariada e deve estar localizada sobre a curva  $I_0(\hat{\rho})$ , representada pela linha escura tracejada. Para essa distribuição o parâmetro  $\rho$ , uma boa medida de dependência se restrito a cópulas gaussianas, é exatamente igual à correlação linear  $\hat{\rho}$ . Se as marginais forem trocadas por marginais não-gaussianas, a informação mútua, independente das marginais, deve permanecer a mesma. Entretanto a correlação, como argumentado acima, deve mudar com a troca de marginais. Uma vez que uma mudança para valores maiores do módulo da correlação linear violaria a condição  $I \geq I_0(\hat{\rho})$ , a única alternativa é que o módulo da correlação diminua. Dessa forma, teríamos uma distribuição conjunta que tem cópula gaussiana com parâmetro  $\rho_0$  e correlação linear  $\hat{\rho} < \rho_0$ . Uma tentativa de identificar o parâmetro  $\rho$  da cópula gaussiana com a correlação linear levaria a atribuir ao par de variáveis uma dependência menor - talvez muito menor - do que a real. Em muitas aplicações isso pode ser perigoso. Em particular em aplicações financeiras o risco

<sup>14</sup> Note a importância de separar conceitualmente o parâmetro correlação, que identifica uma certa distribuição na família de distribuições normais, do funcional são homônimos, o qual estamos chamado de “correlação linear” e que está definido para qualquer distribuição.

<sup>15</sup> Pois independe das marginais.

<sup>16</sup> Essa representação não é única. Está sendo empregada apenas como ilustração. Essas duas grandezas não formam um bom sistema de coordenadas para a variedade de distribuições com cópula gaussiana.




Figura 2 – A correlação linear é subestimada no caso de marginais não-Gaussianas. Se ambas as marginais são Gaussianas, a distribuição conjunta está localizada sobre o limite inferior para a informação mútua. Uma mudança nas marginais mantendo fixa a cópula, preserva a informação mútua, entretanto a correlação estimada deve se deslocar para valores de menor módulo.



de uma operação pode ser subestimado por se subestimar a frequência de co-ocorrência de eventos negativos. É notório que séries temporais financeiras apresentam distribuições marginais com caudas pesadas - e portanto distantes de uma gaussiana. O uso, bastante difundido<sup>17</sup>, de cópulas gaussianas para estimativa de risco combinado com o uso de estimadores baseados na correlação linear nessas condições pode significar que o risco de uma posição é substancialmente maior do que o estimado. Um dos requisitos para uma boa medida de dependência é que, para o caso de cópulas gaussianas, a medida em questão seja função monotônica e crescente do módulo do parâmetro  $\rho$ . Dessa forma, qualquer outra medida de dependência é mais adequada que a correlação linear para estimar a dependência de fato entre duas variáveis com dependência gaussiana.

<sup>17</sup> S. Jones. The formula that felled Wall St. *The Financial Times*, Abril 2009.  
URL <http://www.ft.com/cms/s/2/912d85e8-2d75-11de-9eba-00144feabdco.html>

### *Informação mútua para cópulas elípticas*

O TAU DE KENDALL é um estimador ainda mais completo para  $\rho$ : ele é uma função monotônica do parâmetro  $\rho$  para qualquer cópula pertencente à família elíptica - da qual a gaussiana é um caso particular. Uma distribuição é dita elíptica sempre que:

$$\langle e^{ik \cdot x} \rangle = e^{i\mu^T k} \psi \left( i \frac{k^T \Sigma k}{2} \right), \quad (36)$$

onde  $\Sigma$  é a matriz de covariância e  $\mu$  o vetor de valores esperados de  $x$ . Uma distribuição elíptica padronizada é aquela em que as médias são nulas e todas as variâncias unitárias, de modo que a matriz de covariâncias é igual à matriz de correlações -  $\Sigma_{ij} = \rho_{ij}$ . Denotaremos essa família de distribuições por  $p(x|\Sigma, \psi(\cdot))$ . No caso de  $\Sigma_{ij} = \delta_{ij}$ , a distribuição é invariante por rotações no vetor  $x$  e é dita uma *distribuição esférica* - na família  $p(x|\psi(\cdot))$ .

É POSSÍVEL VER UMA VARIÁVEL DISTRIBUIDA com respeito a uma distribuição elíptica  $x \sim p(x|\Sigma, \psi(\cdot))$  como uma transformação linear de variáveis distribuídas com relação à distribuição esférica com o mesma função  $\psi(\cdot)$ :

$$x_i = \sum_j A_{ij} y_j$$

Onde  $\Sigma = A^T A$  e  $y \sim p(y|\psi(\cdot))$ . Cópulas elípticas são as cópulas associadas a essas distribuições e têm como parâmetros as correlações de pares -  $\rho_{ij}$  - e a função  $\psi(\cdot)$ . A eq.(36) é uma transformação de Fourier, que sempre pode ser invertida para obter a distribuição conjunta. No caso de distribuições elípticas padrão, temos:

$$p(x|\Sigma, \psi(\cdot)) = \int \frac{d^N k}{(2\pi)^N} e^{-ik^T x} \psi \left( i \frac{k^T \Sigma k}{2} \right)$$

podemos introduzir uma função delta e obter:

$$p(x|\Sigma, \psi(\cdot)) = \int du \int \frac{d^N k}{(2\pi)^N} e^{-ik^T x} \psi(u) \delta\left(u - i \frac{k^T \Sigma k}{2}\right)$$

e usando a representação integral da função delta:

$$\begin{aligned} p(x|\Sigma, \psi(\cdot)) &= \int \frac{dud\hat{u}}{2\pi} \int \frac{d^N k}{(2\pi)^N} \psi(u) \exp\left[i\hat{u}\left(u - i \frac{k^T \Sigma k}{2}\right) - ik^T x\right] \\ &= \int \frac{dud\hat{u}}{2\pi} e^{i\hat{u}u} \psi(u) \int \frac{d^N k}{(2\pi)^N} \exp\left[\hat{u} \frac{k^T \Sigma k}{2} - ik^T x\right] \end{aligned}$$

A integral gaussiana sobre  $k$  pode ser feita e temos:

$$\begin{aligned} p(x|\Sigma, \psi(\cdot)) &= \int \frac{dud\hat{u}}{2\pi} e^{i\hat{u}u} \psi(u) N(x|\hat{u}\Sigma) \\ &= \int du p(u) N(x|u\Sigma) = \end{aligned}$$

onde  $N(x|\Sigma)$  é a distribuição normal padronizada com matriz de correlação  $\Sigma$  e  $p(u) = \int du e^{i\hat{u}u} \psi(u)$  é uma certa função ligada à transformada de Fourier de  $\psi(u)$ . Essa representação para as distribuições elípticas pode ser entendida da seguinte forma:  $p(x|\Sigma, \psi(\cdot))$  é a distribuição resultante quando se toma  $x$  de uma gaussiana de matriz de correlação  $u\Sigma$  em que  $u$  é sorteado de acordo com uma distribuição  $p(u)$ . Dessa forma podemos, de forma alternativa, parametrizar a família elíptica pela distribuição  $p(u)$  -  $p(x|\Sigma, p(\cdot))$ . Também podemos escrever de forma mais explícita:

$$p(x|\Sigma, p(\cdot)) = \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \int d^N u \frac{1}{u^{N/2}} p(u) e^{-\frac{1}{2u} x^T \Sigma^{-1} x} \quad (37)$$

$$= \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} x^T \Sigma^{-1} x\right) \quad (38)$$

onde definimos:  $\Psi_j(q) = \int d^j u \frac{1}{u^{j/2}} p(u) e^{-\frac{q}{u}}$ . As marginais de uma distribuição elíptica podem ser facilmente calculadas notando-se que as marginais da normal padronizada são distribuições normais padronizadas sobre 1 variável. Dessa forma:

$$p_j(x_j) = \frac{1}{\sqrt{2\pi}} \int du \frac{1}{\sqrt{u}} p(u) e^{-\frac{x_j^2}{2u}} = \frac{1}{\sqrt{2\pi}} \Psi_1\left(\frac{x_j^2}{2}\right) \quad (39)$$

Finalmente de posse dessas das eqs. (38) e (39) podemos mostrar a seguinte proposição.

**Proposição 1** (Decomposição da informação mútua de uma cópula elíptica). *Se  $C(u, v|\Sigma, p(\cdot))$  é uma cópula elíptica com matriz de correlação  $\Sigma$ , então a informação mútua associada pode ser decomposta na forma:*

$$I(\Sigma, \psi(\cdot)) = I_0(\Sigma) + I[p(\cdot)], \quad (40)$$

onde  $I_0(\Sigma) = -\frac{1}{2} \log \Sigma$  é a informação mútua de uma cópula gaussiana com matriz de correlação  $\Sigma$  e  $I[p(\cdot)]$  é um funcional de  $p(u)$  que é igual à informação mútua da distribuição esférica correspondente e independe da matriz de correlação.

*Demonstração.* Para mostrar essa proposição recorreremos à eq.(9):

$$I = \sum_i^N H[X_i] - H[\mathbf{x}] = NH[X_1] - H[\mathbf{x}]$$

onde a segunda igualdade é obtida notando que as marginais  $p_j(\cdot)$  são todas idênticas. A primeira parcela já é um funcional de  $p(u)$  que independe da matriz de correlação que pode ser escrito como:

$$\begin{aligned} NH[X_1] &= N \int d\mathbf{x} \frac{1}{\sqrt{2\pi}} \Psi_1\left(\frac{x^2}{2}\right) \log \left[ \frac{1}{\sqrt{2\pi}} \Psi_1\left(\frac{x^2}{2}\right) \right] \\ &= \int d^N x \frac{1}{\sqrt{(2\pi)^N}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \mathbf{x}\right) \log \left[ \frac{1}{\sqrt{(2\pi)^N}} \prod_j \Psi_1\left(\frac{x_j^2}{2}\right) \right] \end{aligned}$$

A segunda parcela pode ser explicitamente escrita como:

$$H[\mathbf{x}] = - \int d^N x \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}\right) \log \left[ \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}\right) \right]$$

A inversa da matriz de correlação é simétrica e quadrada, e portanto sempre pode ser escrita como  $\Sigma^{-1} = U^T \Lambda U$ , onde  $U$  é uma matriz unitária e  $\Lambda_{ij} = \delta_{ij} \lambda_j$  é uma matriz diagonal dos autovalores de  $\Sigma^{-1}$ . Fazendo a mudança de variáveis  $\mathbf{y} = U\mathbf{x}$  temos:

$$H[\mathbf{x}] = - \int d^N y \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} \mathbf{y}^T \Lambda \mathbf{y}\right) \log \left[ \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} \mathbf{y}^T \Lambda \mathbf{y}\right) \right]$$

A matriz diagonal  $\Lambda$  pode ser escrita como  $\Lambda = D^T D$ , onde  $D_{ij} = \delta_{ij} \sqrt{\lambda_j}$ . Fazendo a mudança de variáveis<sup>18</sup>  $\mathbf{x} = D\mathbf{y}$ , temos:

$$H[\mathbf{x}] = - \int d^N x \frac{1}{\sqrt{(2\pi)^N}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \mathbf{x}\right) \log \left[ \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \mathbf{x}\right) \right]$$

Uma vez que  $|D| = \prod_i \sqrt{\lambda_i} = \frac{1}{\sqrt{|\Sigma|}}$ . O termo que contém  $|\Sigma|$  dentro do logaritmo pode ser removido da integral<sup>19</sup> e ficamos com:

$$H[\mathbf{x}] = - \int d^N x \frac{1}{\sqrt{(2\pi)^N}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \mathbf{x}\right) \log \left[ \frac{1}{\sqrt{(2\pi)^N}} \Psi_N\left(-\frac{1}{2} \mathbf{x}^T \mathbf{x}\right) \right] + \frac{1}{2} \log |\Sigma|$$

e finalmente podemos escrever<sup>20</sup>:

$$I = I[p(u)] - \frac{1}{2} \log |\Sigma| \quad (41)$$

<sup>18</sup> Vamos renomear a nova variável de integração como  $x$  novamente por conveniência

<sup>19</sup> Note que a normalização de  $p(x)$  exige que  $\int d^N x \psi_N(x^T x) = \sqrt{(2\pi)^N}$

<sup>20</sup> No caso bivariado essa expressão se reduz à expressão 34

onde:

$$I[p(u)] = \int d^N x \frac{1}{\sqrt{(2\pi)^N}} \Psi_N \left( -\frac{1}{2} \mathbf{x}^T \mathbf{x} \right) \log \left[ \frac{\Psi_N \left( -\frac{1}{2} \mathbf{x}^T \mathbf{x} \right)}{\prod_j \Psi_1 \left( \frac{x_j^2}{2} \right)} \right] \quad (42)$$

□

Essa PROPOSIÇÃO nos permite escrever a informação mútua em duas parcelas - uma dependente da estrutura linear de dependência, relacionada à matriz de correlações, e uma parcela que contém informações sobre dependências não-lineares entre as variáveis. Uma vez que a informação mútua é sempre positiva, esse resultado nos permite ainda escrever uma versão mais forte da desigualdade eq.(35) para o caso de cópulas elípticas:

$$I_{XY} \geq I_0(\Sigma_{XY}) \quad (43)$$

onde, nesse caso,  $\Sigma$  não é apenas a matriz de correlações lineares, mas o conjunto de parâmetros que identifica unicamente uma certa distribuição dentro de uma sub-família de cópulas elípticas com mesma função  $\psi(\cdot)$ .

### *Excesso de Informação Mútua*

AS INEQUAÇÕES EQ.(35) E EQ.(43) permitem concluir que a cópula gaussiana é a cópula de menor entropia dado o vínculo de dependências lineares representados por  $\hat{\rho}$  ou  $\Sigma$ . Em outras palavras, a cópula gaussiana é a cópula que assume que uma variável tem a menor quantidade possível de informação a respeito de outra que ainda explica a parte linear da dependência. Além disso, a cópula gaussiana possui apenas a parte linear da informação mútua, e portanto representa uma dependência apenas linear entre as variáveis. O uso dessa cópula portanto representa uma hipótese implícita de dependência linear e mínima entre as variáveis. Caso essa hipótese falhe, um termo adicional deve surgir na informação mútua, que diz respeito à dependência não-linear. Esse termo será chamado “excesso” de informação mútua - entenda-se excesso com relação à cópula linear. A observação de um excesso de informação mútua permite criar um diagnóstico de “gaussianidade” da dependência entre duas variáveis. Para tal é necessário ser capaz de estimar o parâmetro  $\rho$  da distribuição e a informação mútua. Para estimar  $\rho$ , empregaremos o tau de Kendall - uma medida que independe das marginais e permite estimar:

$$\rho = \sin \left( \frac{\pi \tau}{2} \right). \quad (44)$$

O tau de Kendall pode ser estimado empiricamente com um algoritmo simples: dado um conjunto de pontos  $\{x_\mu \sim p(x) | \mu = 1, 2, \dots, P\}$ , temos:

$$\tilde{\tau}[X_i, X_j] = \binom{N}{2}^{-1} \sum_{\mu < \nu} \text{sign}(x_\mu^i - x_\nu^i) \text{sign}(x_\mu^j - x_\nu^j) \quad (45)$$


onde a soma é feita sobre todos os pares  $(\mu, \nu)$ . Um método para estimação da informação mútua foi recentemente publicado por Kraskov et al. [15], baseado em estatísticas de k-vizinhos. Medindo  $I$  e  $\tau$  é possível diagnosticar um eventual “excesso” de informação mútua que, caso presente, indica que a dependência não é mínima e tem uma componente não-linear. Nesses casos a correlação linear não pode ser usada como medida de dependência. Como exemplo desse diagnóstico, mostramos na figura 3 estimativas para essas quantidades para séries temporais de uma seleção de 150 das 500 ações que compõe o índice S&P500, um índice de ações de alta capitalização negociadas em bolsas da NYSE Euronext e da NASDAQ OMX definido e mantido pela Standard & Poor’s. As barras de erro para a informação mútua, que representam um intervalo de confiança de 90%, foram calculadas usando o método de bootstrap, repetindo a estimativa do algoritmo KSG<sup>21</sup> para diversas amostragens com repetição dos dados. O tau de Kendall foi também estimado usando procedimentos padrão como o da eq.(45). Observa-se que uma boa quantidade de pontos apresentam, dentro do intervalo de confiança, um valor para informação mútua não compatível com uma cópula gaussiana. Isso sugere que técnicas de avaliação e administração de risco baseadas no uso de cópulas gaussianas podem subestimar de forma substancial a dependência entre duas ações e o grau de co-movimento que elas apresentam. Na figura 4 por exemplo, mostramos alguns pares de ações com correlações muito pequenas ( $\rho < 0.1$ ) e que no entanto apresentam informação mútua compatível dependência muito maior do que a capturada por essa medida linear.

<sup>21</sup> Alexander Kraskov, Harald Stögbauer, and Peter Grassberger. Estimating mutual information. *Phys. Rev. E*, 69:066138, 2004


### *Ajuste empírico de cópulas via informação mútua*

A DETERMINAÇÃO DE UMA PARTICULAR CÓPULA para realizar essas medidas de risco poderia ser uma alternativa ao uso cego da cópula gaussiana. Uma possível forma de realizar essa determinação é minimizar a divergência de Kullback-Leibler entre a cópula empírica e uma família  $\mathcal{C}_\theta$  de cópulas parametrizadas por um conjunto de parâmetros  $\theta$ :

$$D[C(\mathbf{u}) || C(\mathbf{u}|\theta)] = \int d^N \mathbf{u} \, c(\mathbf{u}) \log \frac{c(\mathbf{u})}{c(\mathbf{u}|\theta)} \quad (46)$$




(a) Todos os pares de ações.




(b) Seleção dos pares cujo limite inferior da barra de erro é maior que a informação mútua gaussiana - excesso de informação não nulo com 90% de confiança (as barras de erro foram removidas para melhor visualização).

Figura 3 – Estimativas para a informação mútua usando o algoritmo KSG contra o tau de Kendall (ou correlação medida via tau de Kendall) para pares de séries temporais de log-retornos diários  $\log \frac{P_{\text{close}}}{P_{\text{open}}}$  (onde  $P_{\text{close}}$  e  $P_{\text{open}}$  são, respectivamente, preços dos ativos na abertura e fechamento diários do mercado) para 150 das ações mais negociadas que compõe o índice S&P500, no período de 02/01/1990 a 16/09/2008 (aproximadamente 4700 pontos por série). As barras de erro representam intervalos de confiança de 90% determinados segundo o procedimento de Bootstrap. Note que, nesse intervalo de confiança, um grande número de pares apresentam um excesso de informação mútua não-nulo com respeito à cópula gaussiana. As linhas tracejadas indicam o limite gaussiano para a informação mútua.

Figura 4 – Seleção de pares de ações com baixa correlação e grande excesso de informação mútua e pares compatíveis com uma distribuição gaussiana. Modelos de risco baseados em medidas de correlação linear devem ser adequados para o segundo grupo e devem falhar seriamente para o primeiro.



(a) Seleção de pares com baixa correlação e grande excesso de informação mútua



(b) Seleção dos pares compatíveis com uma distribuição gaussiana com 90% de confiança.

A minimização desse funcional com respeito a  $\theta$  fornece uma possível cópula  $c(\mathbf{u}|\theta^*)$  que é a mais próxima possível da cópula real dentro dessa família. Essa expressão pode ser manipulada da seguinte forma:

$$D[\cdot|\cdot] = \int d^N \mathbf{u} \, c(\mathbf{u}) \log c(\mathbf{u}) - \int d^N \mathbf{u} \, c(\mathbf{u}) \log c(\mathbf{u}|\theta) \quad (47)$$

$$= I - L_\infty(\theta) \quad (48)$$

onde o primeiro termo é o negativo da entropia de cópula, igual à informação mútua, como mostrado anteriormente, e o segundo termo é o valor assintótico da log-verossimilhança quando o número de amostras é grande:

$$L_N(\theta) = \frac{1}{N} \sum_{\mu=1}^N N \log c(\mathbf{u}_\mu|\theta)$$

Uma vez que  $D[\cdot|\cdot] \geq 0$  e  $I \geq 0$ , então minimizar a divergência de Kullback-Leibler, cujo menor valor possível é nulo, é equivalente a maximizar a log-verossimilhança com a informação mútua como limite. Se a log-verossimilhança fosse conhecida analiticamente isso poderia ser feito de maneira imediata resolvendo a equação:

$$L_\infty(\theta) = I$$

Para um  $I$  determinado empiricamente a partir dos dados, numericamente se necessário. Não há garantia alguma, no entanto de que há solução. Apenas haverá solução para essa equação se a própria cópula original fizer parte da família  $\mathcal{C}_\theta$ . Nesse caso a solução é única. Além disso não é possível conhecer  $L_\infty$  analiticamente sem conhecer a cópula e uma aproximação é necessária. Supondo que a família de cópulas  $\mathcal{C}_\theta$  é suficientemente próxima da cópula original, podemos substituir  $c(\mathbf{u})$  pela própria  $c(\mathbf{u}|\theta)$  na integral e aproximar  $L_\infty(\theta)$  pela informação mútua de  $c(\mathbf{u}|\theta)$ . Dessa forma ficamos com uma espécie de método de “correspondência de momentos” (moment matching): deve ser escolhida na família  $\mathcal{C}_\theta$  a cópula que tem mesma informação mútua que a empiricamente obtida:

$$I(\theta) = I.$$

Novamente, não há garantia de solução, e agora nem mesmo da unicidade da solução. Mas a cópula escolhida certamente será capaz de descrever uma estrutura de dependência mais complexa do que a descrita pela cópula gaussiana. Se a família escolhida for um subconjunto da família de cópulas elípticas, o procedimento pode ser ainda melhorado. Parte do conjunto de parâmetros  $\theta$  corresponde às correlações  $\Sigma$ . Escrevendo  $I(\theta) = I_0(\Sigma) + \Delta I(\theta')$  pode-se já eliminar a parte linear da informação mútua usando o tau de Kendall para calcular  $\Sigma$  e ajustar o excesso de informação mútua ao medido empiricamente.



## Cópula $t$

COMO EXEMPLO DESSE PROCEDIMENTO vamos escolher uma sub-família das cópulas elípticas, as cópulas  $t$ . Essas cópulas, como discutido anteriormente, são as cópulas que se originam da distribuição  $t$  de Student. Quando se permite que o parâmetro  $\nu$  seja contínuo, essa é, em essência, a mesma distribuição obtida pela maximização da chamada entropia de Tsallis, e essa distribuição e sua cópula associada têm recebido certa atenção na literatura de análise financeira por seu bom ajuste empírico a dados de diversas naturezas<sup>22</sup>. O cálculo do excesso de informação mútua da distribuição  $t$  de Student se resume a calcular a eq.(42) - a informação mútua da distribuição  $t$  de Student esférica:

$$p(\mathbf{t} | \hat{\Sigma}, \nu) = \frac{1}{Z_N(\nu)} \left[ 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right]^{-\frac{\nu+N}{2}} \quad (49)$$

onde a normalização é dada por:

$$Z_N(\nu) = \int d^N x \left[ 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right]^{-\frac{\nu+N}{2}} = \frac{B(\frac{\nu}{2}, \frac{N}{2}) \sqrt{(\pi\nu)^N}}{\Gamma(\frac{N}{2})} \quad (50)$$

Uma vez que todas as marginais são idênticas<sup>23</sup> a informação mútua se reduz a:

$$I(\nu) = NH_1(\nu) - H_N(\nu), \quad (51)$$

onde  $H_n(\nu)$  é a entropia de uma distribuição de student  $n$ -dimensional. Para calcular  $H_n$  note que:

$$\begin{aligned} H_n(\nu) &= - \int d^n x \frac{1}{Z_n(\nu)} \left( 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right)^{-\frac{\nu+n}{2}} \left[ -\frac{\nu+n}{2} \log \left( 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right) - \log Z_n(\nu) \right] \\ &= \log Z_n(\nu) + \frac{\nu+n}{2Z_n(\nu)} \int d^n x \left( 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right)^{-\frac{\nu+n}{2}} \log \left( 1 + \frac{\mathbf{x}^T \mathbf{x}}{\nu} \right) \\ &= \log Z_n(\nu) + \frac{(\nu+n)\Omega_n}{2Z_n(\nu)} \int_0^\infty dr r^{n-1} \left( 1 + \frac{r^2}{\nu} \right)^{-\frac{\nu+n}{2}} \log \left( 1 + \frac{r^2}{\nu} \right) \\ &= \log Z_n(\nu) + \frac{(\nu+n)\Omega_n \sqrt{\nu^n}}{2Z_n(\nu)} \int_0^\infty du u^{n-1} \left( 1 + u^2 \right)^{-\frac{\nu+n}{2}} \log \left( 1 + u^2 \right) \\ &= \log Z_n(\nu) + \frac{(\nu+n)\Omega_n \sqrt{\nu^n}}{2Z_n(\nu)} R_n(\nu) \end{aligned}$$

Onde  $\Omega_n = \frac{2\pi^{n/2}}{\Gamma(\frac{n}{2})}$  é a área de uma esfera unitária em  $n$  dimensões e

$$R_n(\nu) = \int_0^\infty du u^{n-1} \left( 1 + u^2 \right)^{-\frac{\nu+n}{2}} \log \left( 1 + u^2 \right).$$

Essa integral pode ser feita com o auxílio de um truque similar ao truque de réplicas comum em mecânica estatística. Se notarmos que  $\log(x) = \lim_{r \rightarrow 0} \frac{\partial}{\partial r} x^r$  podemos escrever<sup>24</sup>:

<sup>22</sup> Stefano Demarta and Alexander J. McNeil. The  $t$  copula and related copulas. *International Statistical Review*, 73(1):111–129, 2005; and Lisa Borland. Option pricing formulas based on a non-gaussian stock price model. *Phys. Rev. Lett.*, 89(9):098701, Aug 2002. DOI: 10.1103/PhysRevLett.89.098701

<sup>23</sup> Todas são iguais à distribuição  $t$  de Student em uma dimensão com o mesmo parâmetro  $\nu$

<sup>24</sup> Pois:

$$\begin{aligned} \int_0^\infty du u^{n-1} \left( 1 + u^2 \right)^{-\alpha} &= B\left(\alpha - \frac{n}{2}, \frac{n}{2}\right), \\ \frac{\partial}{\partial x} B(x, y) &= -B(x, y)(\psi(x+y) - \psi(x)) \end{aligned}$$

$$R_n(\nu) = \lim_{r \rightarrow 0} \frac{\partial}{\partial r} B\left(\frac{\nu}{2} - r, \frac{n}{2}\right) = -B\left(\frac{\nu}{2}, \frac{n}{2}\right) \left[ \psi\left(\frac{\nu+n}{2}\right) - \psi\left(\frac{\nu}{2}\right) \right]$$

onde  $B(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$  é a função beta e  $\psi(x)$  é a função digamma, substituindo esse resultado na expressão original e escrevendo todos os termos explicitamente temos:

$$H_n(\nu) = \log \left[ \frac{\sqrt{(\pi\nu)^n} B\left(\frac{\nu}{2}, \frac{n}{2}\right)}{\Gamma\left(\frac{n}{2}\right)} \right] + \frac{\nu+n}{2} \left[ \psi\left(\frac{\nu+n}{2}\right) - \psi\left(\frac{\nu}{2}\right) \right] \quad (52)$$

Para o caso  $n = 1$  isso se reduz a:

$$H_1(\nu) = \log \left[ \sqrt{\nu} B\left(\frac{\nu}{2}, \frac{1}{2}\right) \right] + \frac{\nu+1}{2} \left[ \psi\left(\frac{\nu+1}{2}\right) - \psi\left(\frac{\nu}{2}\right) \right] \quad (53)$$

E a informação mútua  $I = NH_1(\nu) - H_N(\nu)$  finalmente pode ser escrita:

$$I = \log \left\{ \frac{\left[ B\left(\frac{\nu}{2}, \frac{1}{2}\right) \right]^N \Gamma\left(\frac{N}{2}\right)}{\pi^{\frac{N}{2}} B\left(\frac{\nu}{2}, \frac{N}{2}\right)} \right\} - \frac{\nu(N-1)}{2} \psi\left(\frac{\nu}{2}\right) + \frac{N(\nu+1)}{2} \psi\left(\frac{\nu+1}{2}\right) - \frac{\nu+N}{2} \psi\left(\frac{\nu+N}{2}\right).$$

Para  $N = 2$  isso se reduz a:

$$I(\nu) = 2 \log \left( \sqrt{\frac{\nu}{2\pi}} B\left(\frac{\nu}{2}, \frac{1}{2}\right) \right) - \frac{2+\nu}{\nu} + (1+\nu) \left[ \psi\left(\frac{\nu+1}{2}\right) - \psi\left(\frac{\nu}{2}\right) \right]$$

Finalmente, a expressão acima pode ser usada, segundo o método discutido na seção , para ajustar cópulas  $t$  a dados empíricos. Como ilustração, a figura 5 apresenta uma série de simulações de ajuste com dados sorteados de uma cópula  $t$  com diversos valores de correlação e  $\nu$  conhecidos. O excesso de informação mútua é estimado usando o algoritmo KSG <sup>25</sup> e o tau de Kendall e plotado em função do  $\nu$  conhecido. A linha cheia corresponde à eq.(54). Esse gráfico mostra que, exceto por um ponto que não pode ser recuperado<sup>26</sup>, é possível recuperar cópulas  $t$  a partir de dados experimentais através desse procedimento.


## Conclusões

A LITERATURA EM TEORIA DE INFORMAÇÃO E TEORIA DE CÓPULAS E DEPENDÊNCIA ESTATÍSTICA - ambas com décadas de existência - se desenvolveram em relativo isolamento, com apenas pontos muito recentes de contato. Neste trabalho tentamos discutir as consequências

<sup>25</sup> Alexander Kraskov, Harald Stögbauer, and Peter Grassberger. Estimating mutual information. *Phys. Rev. E*, 69:066138, 2004

<sup>26</sup> Para um valor muito pequeno de  $\nu$ , para o qual a distribuição  $t$  começa a apresentar diversas patologias, como variância infinita.

Figura 5 – Excesso de informação mútua na cópula  $t$ .  $I(\nu)$ , como dado na eq.(54). Círculos mostram estimativas para 20 amostragens de pontos de uma cópula  $t$  usando o método de “moment matching” para diversos valores de correlação e  $\nu$ .



de alguns desses pontos e conexões entre os dois tópicos. A teoria de cópulas pode ser usada para decompor as distribuições conjuntas em flutuações idiossincráticas das marginais de cada variável e flutuações devidas ao acoplamento entre as variáveis. A conexão com a teoria de informação permite levar adiante essa decomposição e isolar contribuições à informação total contida na distribuição em partes relativas às marginais, ao acoplamento de natureza linear e acoplamentos de mais alta ordem. Essa decomposição oferece testes simples a respeito da linearidade e “gaussianidade” do acoplamento e também sugere um método de ajuste de cópulas baseados no ajuste da informação mútua. Essa abordagem também clarifica os perigos do uso da correlação linear como medida de dependência em séries financeiras para, por exemplo, estimativas de riscos de contratos complexos e otimização de carteiras, pois essa medida é fadada a subestimar a dependência em séries em que flutuações não-gaussianas são esperadas. Finalmente, pensamos que uma conexão entre essas duas áreas - teoria de informação e teoria de dependência estatística - pode ser útil em fornecer conceitos e técnicas novas para o estudo de sistemas complexos.



# *Um Modelo para emergência de autoridade em sociedades humanas.*

## *Introdução*

PRIMATAS TEM VIDAS SOCIAIS E POLÍTICAS muito intensas<sup>27</sup>. Enquanto em geral a maioria dos grandes primatas vivem em sociedades hierárquicas, os humanos se destacam pela variabilidade de suas experiências sociais nesse espectro - desde sociedades fortemente centralizadas e hierárquicas até sociedades basicamente equalitárias, em que não há autoridades centrais ou concentração de poder. Nossa intenção é desenvolver um modelo matemático para a formação de estruturas sociais baseado em recentes observações nos campos da arqueologia, primatologia e neurociências.

## *Evidências empíricas*

### *“U-shaped evolution” e dinâmica da organização social em primatas pré-humanos*

O registro arqueológico revela uma dinâmica temporal na organização social dos humanos através da pré-história. Os humanos, descendendo de primatas com provável organização social hierárquica, similar às dos grandes primatas mais próximos - chimpanzés, bonobos e gorilas - passaram por um período de grupos equalitários, sem autoridade central, com baixa densidade populacional. No neolítico houve uma transição para grupos fortemente hierárquicos, conforme a densidade populacional aumenta após a revolução agrícola. Esse quadro é ilustrado pela figura 6. Evidências etnográficas também apontam para uma relação entre o tamanho dos grupos de humanos caçadores-coletores e suas formas de organização social<sup>28</sup>. Grupos pequenos de humanos tendem a apresentar organização equalitária, sem concentração de poder. Grupos maiores tendem a apresentar organizações hierárquicas, concentração de poder e hereditariedade de poder.

<sup>27</sup> Frans de Waal. *Chimpanzee Politics: Power and Sex Among Apes*. Johns Hopkins University Press, Baltimore, 4th edition, 2007

<sup>28</sup> Thomas E. Currie, Simon J. Greenhill, Russell D. Gray, Toshikazu Hasegawa, and Ruth Mace. Rise and fall of political complexity in island South-East Asia and the Pacific. *Nature*, 467(7317):801–4, oct 2010. DOI: 10.1038/nature09461




Figura 6 – Ilustração da história da organização social dos humanos e primatas pré-humanos.

<sup>29</sup> R. I. M. Dunbar. Cognitive constraints on the structure and dynamics of social networks. *Group Dynamics: Theory, Research, and Practice*, 12(1): 7–16, 2008; R I M Dunbar. The social brain hypothesis and its implications for social evolution. *Annals of human biology*, 36(5):562–72, 2009. DOI: 10.1080/03014460902960289; R. I. M. Dunbar. Coevolution of neocortical size, group size and language in humans. *Behavioral and Brain Sciences*, 16(04):681, feb 2010; LC Aiello and RIM Dunbar. Neo-cortex size, group size, and the evolution of language. *Current Anthropology*, 34(2):184–193, 1993; and T H Joffe and R I Dunbar. Visual and socio-cognitive information processing in primate brain evolution. *Proceedings. Biological sciences / The Royal Society*, 264(1386):1303–7, sep 1997. DOI: 10.1098/rspb.1997.0180

### *Evolução do cérebro primata e a Teoria Maquiavélica*

Diversos trabalhos<sup>29</sup> relacionam o tamanho relativo de regiões do cérebro de diversas espécies de primatas a medidas relacionadas com a capacidade social da espécie, como tamanho dos grupos em que vivem, o tamanho de coalizões, número médio de indivíduos que interagem diretamente, etc. O que é tipicamente encontrado é ilustrado na figura 7. Nessa figura mostra-se um gráfico do tamanho médio do grupo em função da razão média entre o volume do neo-córtex - região do cérebro dedicada ao planejamento, raciocínio, linguagem, entre outras funções cognitivas de ordem superior - e o volume total do cérebro para diversas espécies de primatas. O gráfico sugere uma relação do tipo lei de potência entre as duas grandezas, similar a encontradas em diversas outras comparações desse tipo. Em essência, essa relação sugere que a capacidade cognitiva dos primatas está intimamente relacionada a sua necessidade de dar conta de interações sociais cada vez mais complexas e sugere um cenário em que o rápido crescimento na importância relativa do neo-córtex é uma resposta a uma pressão seletiva associada a essa necessidade de interação social.

### *Dados etnoráficos (?)*

### *Um modelo mecanico-estatístico baseado em agentes*


#### *Modelo de Agentes*

#### *Representação da Estrutura Social*

#### *Custo social e custo cognitivo*

A CAPACIDADE DO CÉREBRO DE PROCESSAR RELAÇÕES SOCIAIS é limitada. Considere um grupo de agentes dotados de certa capacidade

Figura 7 – Gráfico em escala di-logaritmica do tamanho médio do grupo em função da razão média entre o volume do neo-córtex e o volume total do cérebro para diversas espécies de primatas. Dados disponíveis em [8].



cognitiva limitada e engajados em atividades sociais. Cada agente carrega um registro mental da informação que possui a respeito das relações sociais entre os membros do seu grupo. Essa informação consiste de variáveis associadas a como cada par de indivíduos do grupo se comporta socialmente: a probabilidade de serem adversários em uma disputa, ou aliados em uma coalizão, a capacidade de cooperarem em uma atividade conjunta, etc. Essa informação é adquirida através da história do grupo, de observação e de aprendizado social (“fofoca” ou *gossip*) e é utilizada para subsidiar decisões sociais a serem tomadas pelo agente. Segundo as hipóteses aqui adotadas, a aquisição desse tipo de informação social é uma atividade cognitivamente custosa. A capacidade limitada de processar essas informações implica que para mantê-las atualizadas, o indivíduo precisa desviar recursos que poderiam ser aplicados em outras atividades - coleta de alimentos, construção de abrigos, etc. Há evidências <sup>30</sup>de que o rastreamento de relações sociais demanda um considerável tempo dos indivíduos adultos em tribos de chimpanzés e humanos. Conforme se aumenta o tamanho do grupo, esse custo cresce com o número de ligações sociais possíveis e, portanto, quadraticamente com o número de indivíduos. Isso pode tornar a estratégia de adquirir e manter informações sobre todas as ligações sociais possíveis no grupo pouco adaptativa. Pode ser preferível ao agente nesse caso obter apenas informação sobre certas ligações sociais importantes e fiar-se em heurísticas para inferir as outras relações sociais (regras como “amigo do amigo é amigo”, etc...).

A REALIZAÇÃO QUANTITATIVA DESSA IDÉIA será feita representando

<sup>30</sup> Frans de Waal. *Chimpanzee Politics: Power and Sex Among Apes*. Johns Hopkins University Press, Baltimore, 4th edition, 2007; and Frans de Waal. *Peacemaking among primates*. Harvard University Press, Cambridge, Massachusetts, 1990. ISBN 0674659201

o modelo mental que cada agente faz das relações sociais do grupo por um grafo cujos nós representam os indivíduos do grupo e as arestas representam para que pares de indivíduos o agente em questão está dispendendo recursos para obter informações sociais. O custo de manter esse modelo mental consiste em duas partes:

1. O **CUSTO COGNITIVO** de adquirir e manter informação dos diferentes pares de indivíduos. Se o agente tem recursos cognitivos limitados, manter essas informações é custoso. Se assumirmos que o investimento de recursos para obter informações sobre cada aresta do grafo é constante, o custo cognitivo total é proporcional ao número de arestas do grafo.
2. O **CUSTO SOCIAL** de falhar em determinar corretamente a relação entre dois indivíduos. Se um agente comete um erro desse tipo, e toma decisões baseadas nesse erro, ele pode incorrer em custos - avaliar incorretamente em que lado de uma disputa um indivíduo vai se posicionar, falhar em reconhecer uma coalizão em formação, etc. Para inferir relações sociais desconhecidas, que não possuem uma aresta no grafo, o agente recorre a heurísticas que agem sobre trajetos de arestas conhecidas (regras do tipo “amigo do amigo”). Quanto mais longos os trajetos a serem percorridos, maior é a probabilidade de erro. Portanto, o custo social esperado deve ser proporcional à distância geodésica média entre os nós do grafo.

O custo total será dado, portanto, por:

$$H = \frac{N_e}{\alpha} + \bar{L} \quad (55)$$

Onde  $\bar{L}$  é a distancia geodésica média do grafo,  $\alpha$  é uma constante associada à capacidade cognitiva do agente (quanto maior  $\alpha$ , menos importante é o custo cognitivo) e  $N_e$  é o número de arestas do grafo. Note que tipicamente  $N_e$  escala como uma fração do número total de arestas possíveis  $N(N-1)/2$  e que  $\bar{L}$  escala tipicamente com  $\log(N)$  para grafos aleatórios. É, portanto, interessante, reescrever (55), a menos de uma constante multiplicativa, como:

$$H = \phi_e + a\bar{L} \quad (56)$$

onde  $\phi_e = \frac{N_e}{N(N-1)/2}$  é a fração de arestas ocupadas e  $a = \frac{2\alpha}{N(N-1)}$  é a constante de acoplamento adequada, a capacidade cognitiva por aresta.




Figura 8 – Exemplo de grafo social - um grafo completamente conectado. Um agente com essa estratégia despende recursos para conhecer todas as relações sociais do grupo




Figura 9 – Exemplo de grafo social - um grafo estrelado. Um agente com



### *Dinâmica para agentes isolados - máxima entropia*

PARA QUE UM MODELO POSSA SER ESTABELECIDO, não basta a expressão para o custo, mas uma descrição de que ações o agente deverá tomar com base em sua aferição do custo. A estratégia do agente é definida por uma certa escolha de arestas a investir. Em uma primeira abordagem, atribuímos ao agente a tendência a usar a estratégia que minimiza o custo total. Então deveríamos procurar pelo grafo definido por:

$$G_*(\alpha) = \arg \min_G H(G, \alpha) \quad (57)$$

Se  $\alpha \gg 1$ , então as limitações cognitivas são menos e menos importantes. O grafo que minimiza o custo é o grafo que minimiza a distância geodésica média - um grafo totalmente conectado como o da figura 8. Se  $\alpha \ll 1$ , então as limitações cognitivas se tornam mais e mais importantes, e o grafo ótimo é aquele que minimiza o número de arestas, enquanto ainda mantendo uma distância média finita - um grafo em forma de estrela <sup>31</sup> como o da figura 9. Para valores intermediários de  $\alpha$ , o grafo ótimo possui configurações intermediárias entre esses dois extremos.

PODEMOS RELAXAR O VÍNCULO DE ESTRITA MINIMIZAÇÃO e propor o seguinte modelo: o agente decide sua estratégia através de uma dinâmica interna que ocorre em seu cérebro, ditada por regras que levam em conta o custo total. Podemos então associar probabilidades às estratégias de acordo com nossa expectativa de que grafos devem surgir dessa dinâmica. Se não conhecemos detalhes da dinâmica, mas temos informação de que o valor esperado do custo total é uma variável importante, o procedimento bayesiano adequado é associar ao grafo uma distribuição de máxima entropia, restringida pelo valor do custo total. A distribuição resultante é a distribuição de Gibbs:

$$p(G) = \frac{q(G)}{Z} e^{-\beta H(G)} \quad (58)$$

onde  $\beta$ , uma espécie de inverso de temperatura, regula a importância relativa dos efeitos que o custo  $H(G)$  e outros efeitos negligenciados pelo modelo, e  $q(G)$  é a atribuição de probabilidades a priori. Assumiremos probabilidades uniformes a priori, com a restrição de que o grafo seja conexo (veja nota <sup>31</sup>). A atribuição de probabilidades da equação (58) torna o problema de determinar as propriedades macroscópicas desse sistema em um problema de mecânica estatística, cuja variável dinâmica é a matriz de adjacências do grafo  $G$ :

$$M_{ij} = \begin{cases} 1 & \text{se } i \text{ e } j \text{ estão ligados por uma aresta} \\ 0 & \text{outro caso} \end{cases} \quad (59)$$

<sup>31</sup> Estritamente para  $\alpha = 0$  o grafo ótimo é o grafo sem aresta alguma. Não há prescrição canônica para a distância geodésica média de um grafo sem arestas. Adotaremos aqui a convenção de que se não é possível desenhar um caminho entre dois nós (em outras palavras: dois nós que pertencem a diferentes componentes do grafo), então a distância entre eles é infinita. Isso restringe nossa análise apenas a grafos conexos. Mesmo entre os grafos conexos, a estrela não é o único mínimo do custo acima para  $\alpha$  estritamente zero - o grafo caminho também é possível. Entretanto, para o grafo caminho,  $\bar{L}$  é proporcional a  $N$ , e portanto, para  $\alpha \rightarrow +0$  o único mínimo existente quando  $\alpha > 0$  tem grafo estrela como limite.


### Interpretação do parâmetro $\beta$

#### Resultados numéricos para agentes isolados

SIMULAÇÕES DE MONTE CARLO desse modelo foram feitas usando o algoritmo de Metrópolis. Partindo de um grafo inicial aleatório (sorteado do ensemble de Erdos-Renyi, com fração de arestas  $\frac{1}{2}$ ), a cada passo do algoritmo é proposta uma mudança em uma aresta do grafo - adicionando uma aresta faltante ou removendo uma aresta existente. Caso a mudança não quebre a conectividade do grafo, ela será aceita com probabilidade dada pelo fator de Gibbs:


$$e^{-\beta(H(G')-H(G))}. \quad (60)$$

Figura 10 – Corte do diagrama de fases apresentando a média térmica obtida via Monte Carlo dos parâmetros de ordem normalizados  $d_{\max}$  e  $d_{\text{avg}}$  em função de  $\alpha$ , com temperatura e número de agentes fixo, bem como seus desvios padrão. Sobreposto ao gráfico se observam exemplos de arquiteturas do grafo sorteadas da distribuição de equilíbrio na região correspondente do diagrama.




NA FIGURA 10 temos um corte do diagrama de fase desse modelo com temperatura e número de agentes constante, variando o parâmetro  $\alpha$ . Seja  $d_i$  o grau do  $i$ -ésimo nó do grafo de um agente escolhido ao acaso. No painel superior destacamos dois parâmetros de ordem:  $d_{\max} = \frac{1}{N-1} \max(d_1, d_2, \dots, d_N)$ , em azul, é proporcional ao grau do nó mais bem conectado do grafo, e  $d_{\text{avg}} = \frac{1}{N(N-1)} \sum_{i=1}^N d_i$ , em vermelho, é proporcional ao grau médio de todos os nós do grafo. Uma vez que o maior possível grau para um nó é  $N-1$ , esses parâmetros foram normalizados para que o valor máximo seja 1. As linhas sólidas

Figura 11 – Diagrama de fases apresentando a razão  $\frac{d_{avg}}{d_{max}}$  em função de  $\alpha$  e temperatura, para um número fixo de agentes.



correspondem à média térmica obtida através da simulação de Monte Carlo do modelo, enquanto o sombreado ao redor da linha representa o desvio padrão obtido da mesma forma. No painel inferior apresentamos novamente o desvio padrão para melhor visualização. Sobrepostas aos gráficos estão figuras representativas de grafos sorteados da distribuição de equilíbrio em pontos correspondentes do diagrama de fases. Como observado anteriormente, para  $a = \frac{2\alpha}{N(N-1)}$  pequeno - baixa capacidade cognitiva, ou grupos grandes - há uma fase em que o grafo se organiza como uma estrela. Para  $a$  grande - alta capacidade cognitiva ou grupos pequenos - o grafo tem conectividade densa, tendendo a um grafo totalmente conectado conforme o parâmetro aumenta.

Figura 12 – Valor crítico do parâmetro  $a$  em função da temperatura para diferentes tamanhos do sistema.




UMA CARACTERÍSTICA É INTERESSANTE na região intermediária, entretanto: o grafo continua com um nó fortemente central e baixa conectividade na periferia para valores de  $a$  relativamente grandes, até que uma repentina mudança de comportamento, acompanhada de um pico nas variâncias dos parâmetros de ordem, indicando uma aparente transição de fase. Nessa segunda fase, a conectividade do nó mais central já não é mais máxima, e a conectividade dos nós periféricos é comparável à do nó central. Conforme  $a$  cresce, o grafo tende a se tornar totalmente conectado, com valores de  $d_{\max}$  e  $d_{\text{avg}}$  compatíveis com os de um grafo no ensemble de Erdos-Renyi (um grafo aleatório, com número médio de arestas fixo).

NA FIGURA 11 temos um diagrama de fases completo variando  $\alpha$  e a temperatura para um número fixo de agentes. A variável descrita no mapa de cores é a razão  $\frac{d_{avg}}{d_{max}}$ . Esse diagrama mostra uma linha de transição de fases entre a região azul escura - a região em que a organização do grafo é fortemente centralizada, com nós periféricos pouco conectados, e uma região em que a razão  $\frac{d_{avg}}{d_{max}}$  é menos extrema. Acima de uma temperatura crítica essa fase não é mais observada. A região vermelho escura corresponde à fase totalmente conectada, ou situações bem próximas disso. Nessa região não há grandes saltos nos parâmetros de ordem, que mudam continuamente com a temperatura e  $\alpha$ . A linha de transição de fase pode ser observada para diferentes valores da temperatura na figura 12. Note que para  $\beta^{-1} \rightarrow 0$ , temos  $\alpha^* = 1$ .

### Dinâmica para muitos agentes

AS FIGURAS ACIMA tratam de propriedades independentes da interação entre os agentes. Essa interação, como dito anteriormente, será introduzidas na forma de aprendizado social (“fofoca” ou *gossip*). Durante a simulação de Monte Carlo, com uma certa probabilidade  $g$ , dois agentes são sorteados e trocam informação uma aresta com probabilidade proporcional ao fator de Gibbs (60). Esse procedimento visa imitar o aprendizado social observado em humanos <sup>32</sup>. Essa escolha de interação não altera os diagramas já mostrados, mas introduz correlação entre os grafos de diferentes agentes. Na figura 13 são exibidas

<sup>32</sup> Robin Dunbar. *How Many Friends Does One Person Need?: Dunbar's Number and Other Evolutionary Quirks*. Faber and Faber, 2010



duas grandezas que quantificam a correlação entre os grafos na fase es-

trela. Vamos denotar por  $c_i$  o label que identifica o nó central do grafo do  $i$ -ésimo agente. Para um certo número  $N$  de agentes temos então o conjunto  $\{c_1, c_2, \dots, c_N\}$ . Seja a variável aleatória  $c$  definida como um valor sorteado ao acaso desse conjunto. A primeira grandeza do grafo, correspondente às linhas tracejadas, é dada por  $\max_c \mathbb{Pr}[(\cdot|c)$ , ou seja, a frequência do agente que mais frequentemente é o centro de algum grafo naquele passo do algoritmo. Isso corresponde de forma grosseira a que fração dos agentes tem grafos estrela com o mesmo nó ocupando o centro da estrela. A segunda variável é, a menos de uma constante multiplicativa, simplesmente a entropia da distribuição de  $c$ :  $S(c) = -\sum_c \mathbb{Pr}[(\cdot|c) \log \mathbb{Pr}[(\cdot|c)$ . Ambas as grandezas são calculadas para grafos em forma de estrela, em função da probabilidade de encontro entre dois agentes dada por  $g$ , para valores fixos de temperatura, variando-se o número de agentes. O resultado mostra que, para baixos valores de  $g$ , a probabilidade de que um certo nó seja o centro de um agente tomado ao acaso é aproximadamente uniforme, e nenhum dos nós domina como centro de uma fração substancial de grafos. Para valores maiores de  $g$ , os grafos estrela tendem a se correlacionar e o mesmo nó pode ser central em uma grande fração de agentes.

É POSSÍVEL, dessa forma, distinguir três situações, ou “fases” desse modelo:

1. Para  $a$  grande, ou seja, grupos de tamanho pequeno ou agentes com grande capacidade cognitiva, os agentes possuem modelos mentais do panorama social do seu grupo em que nenhum agente em particular ocupa uma posição central. Em outras palavras, a representação mental das redes sociais nesse grupo são todas simétricas e nenhum agente se destaca.
2. Para  $a$  pequeno e  $g$  pequeno, ou seja, grupos de tamanho grande ou agentes com capacidade cognitiva pequena, e pouca interação social, cada agente possui um modelo mental da paisagem social que privilegia um dos agentes como central na definição de todas as relações sociais do grupo. Suas decisões em jogos sociais são tomadas levando em conta a natureza das relações sociais de todos os agentes com esse agente central. Entretanto os nós centrais de cada agente são sorteados aleatoriamente e, de certa forma, apesar de haver uma quebra de simetria na representação mental que cada agente faz do grupo, a situação global ainda é simétrica.
3. Para  $a$  pequeno e  $g$  grande, ou seja, grupos de tamanho grande ou agentes com capacidade cognitiva pequena, e interação social intensa, todos os agentes possuem o mesmo modelo mental: uma rede

social centrada em torno de um agente específico, que se torna a medida de todas as relações sociais no grupo. Todo agente do grupo usa as conexões desse mesmo agente central como informação mais relevante na tomada de decisões em jogos sociais. Esse agente central está posicionado de forma privilegiada como central na solução de dilemas sociais, formação de coalizões e outras atividades sociais do grupo.

Postulando que o capital social derivado dessa posição central quebra a simetria do resultado desses jogos sociais de maneira vantajosa ao agente central, esse resultado é compatível com as observações empíricas descritas no início do texto. ...

*Resultados numéricos para muitos agentes*

*Sumarização e interpretação dos Resultados*

*Conclusão*





## *Conclusão e Observações Finais*

...

...

...



## Referências Bibliográficas

- [1] LC Aiello and RIM Dunbar. Neocortex size, group size, and the evolution of language. *Current Anthropology*, 34(2):184–193, 1993.
- [2] Lisa Borland. Option pricing formulas based on a non-gaussian stock price model. *Phys. Rev. Lett.*, 89(9):098701, Aug 2002. DOI: 10.1103/PhysRevLett.89.098701.
- [3] Thomas E. Currie, Simon J. Greenhill, Russell D. Gray, Toshikazu Hasegawa, and Ruth Mace. Rise and fall of political complexity in island South-East Asia and the Pacific. *Nature*, 467(7317):801–4, oct 2010. DOI: 10.1038/nature09461.
- [4] Frans de Waal. *Peacemaking among primates*. Harvard University Press, Cambridge, Massachusetts, 1990. ISBN 0674659201.
- [5] Frans de Waal. *Chimpanzee Politics: Power and Sex Among Apes*. Johns Hopkins University Press, Baltimore, 4nd edition, 2007.
- [6] Stefano Demarta and Alexander J. McNeil. The t copula and related copulas. *International Statistical Review*, 73(1):111–129, 2005.
- [7] R. I. M. Dunbar. Cognitive constraints on the structure and dynamics of social networks. *Group Dynamics: Theory, Research, and Practice*, 12(1):7–16, 2008.
- [8] R I M Dunbar. The social brain hypothesis and its implications for social evolution. *Annals of human biology*, 36(5):562–72, 2009. DOI: 10.1080/03014460902960289.
- [9] R. I. M. Dunbar. Coevolution of neocortical size, group size and language in humans. *Behavioral and Brain Sciences*, 16(04):681, feb 2010.
- [10] Robin Dunbar. *How Many Friends Does One Person Need?: Dunbar's Number and Other Evolutionary Quirks*. Faber and Faber, 2010.
- [11] E. T. Jaynes. *Probability Theory: The Logic of Science*. Cambridge University Press, Cambridge, 2003.

- [12] Rick L. Jenison and Richard A. Reale. The shape of neural dependence. *Neural Computation*, 16:665 – 672, 2004.
- [13] T H Joffe and R I Dunbar. Visual and socio-cognitive information processing in primate brain evolution. *Proceedings. Biological sciences / The Royal Society*, 264(1386):1303–7, sep 1997. DOI: 10.1098/rspb.1997.0180.
- [14] S. Jones. The formula that felled Wall St. *The Financial Times*, Abril 2009. URL <http://www.ft.com/cms/s/2/912d85e8-2d75-11de-9eba-00144feabdc0.html>.
- [15] Alexander Kraskov, Harald Stögbauer, and Peter Grassberger. Estimating mutual information. *Phys. Rev. E*, 69:066138, 2004.
- [16] Jian Ma and Zengqi Sun. Mutual information is copula entropy. *Tsinghua Science and Technology*, 16(1):51 – 54, 2011. ISSN 1007-0214. DOI: 10.1016/S1007-0214(11)70008-6. arXiv:0808.0845.
- [17] Roger B. Nelsen. *An Introduction to Copulas*. Springer Series in Statistics. Springer, New York, 2nd edition, 2006. ISBN 0387986235.
- [18] A. Renyi. On measures of dependence. *Acta. Math. Acad. Sci. Hungar.*, 10:441–451, 1959.
- [19] B. Schweizer and E. F. Wolff. On nonparametric measures of dependence for random variables. *The Annals of Statistics*, 9(4):879 – 885, 1981.
- [20] A. Sklar. Fonctions de répartition à n dimensions et leurs marges. *Publ. Inst. Statist. Univ. Paris*, 8:229–231, 1959.